

# Lab03

## Caracterizando a atividade de code review no GitHub

*Análise de correlação entre métricas de Pull Requests e resultados do code review*

---

**Júlia Medeiros & Thiago Laass**

|                                                              |           |
|--------------------------------------------------------------|-----------|
| <b>Sumário</b>                                               | <b>2</b>  |
| <b>1. Introdução</b>                                         | <b>3</b>  |
| Contextualização                                             | 3         |
| O problema investigado                                       | 3         |
| Questões de pesquisa                                         | 3         |
| Hipóteses iniciais                                           | 3         |
| Objetivo                                                     | 4         |
| <b>2. Metodologia</b>                                        | <b>5</b>  |
| Passo a passo do experimento                                 | 5         |
| Critérios de seleção                                         | 5         |
| Decisões metodológicas                                       | 6         |
| Métricas analisadas                                          | 6         |
| <b>3. Resultados</b>                                         | <b>7</b>  |
| 3.1 Composição do dataset                                    | 7         |
| 3.2 Estatísticas descritivas                                 | 7         |
| 3.3 Panorama das correlações de Spearman                     | 7         |
| 3.4 Correlações de Spearman - Status do PR (RQ01–RQ04)       | 8         |
| RQ02 - Tempo de análise × Status                             | 8         |
| RQ01 - Tamanho × Status                                      | 9         |
| RQ03 - Descrição × Status                                    | 9         |
| RQ04 - Interações × Status                                   | 10        |
| 3.5 Correlações de Spearman - Número de revisões (RQ05–RQ08) | 10        |
| RQ08 - Interações × Número de revisões                       | 11        |
| RQ05 - Tamanho × Número de revisões                          | 11        |
| <b>4. Discussão dos resultados</b>                           | <b>13</b> |
| RQ01 - Tamanho × Status                                      | 13        |
| RQ02 - Tempo de análise × Status                             | 13        |
| RQ03 - Descrição × Status                                    | 13        |
| RQ04 - Interações × Status                                   | 13        |
| RQ05 - Tamanho × Número de revisões                          | 13        |
| RQ06 - Tempo de análise × Número de revisões                 | 13        |
| RQ07 - Descrição × Número de revisões                        | 14        |
| RQ08 - Interações × Número de revisões                       | 14        |
| Limitações                                                   | 14        |
| Síntese das hipóteses                                        | 14        |
| <b>5. Conclusão</b>                                          | <b>16</b> |
| Próximos passos                                              | 16        |

# 1. Introdução

## Contextualização

A prática de code review é central no desenvolvimento de software open source. No GitHub, ela se materializa através de Pull Requests (PRs): um desenvolvedor submete código, revisores avaliam e, ao final do processo, o PR é aceito (MERGED) ou rejeitado sem merge (CLOSED). Entender quais características observáveis de um PR se associam a esse desfecho, e a quantidade de revisões acumuladas, é relevante tanto para pesquisadores de engenharia de software quanto para equipes que desejam melhorar seus processos de revisão.

## O problema investigado

A pergunta central deste laboratório é: características mensuráveis de um PR (tamanho, tempo de análise, descrição e interações entre participantes) estão relacionadas ao desfecho do review (MERGED/CLOSED) e ao número de revisões registradas? Identificar essas associações permite, por exemplo, apontar se PRs maiores recebem mais atenção, se PRs com descrições detalhadas têm maior probabilidade de serem aceitos, ou se o volume de comentários sinaliza dificuldades que levam à rejeição.

## Questões de pesquisa

- **RQ01:** Qual a relação entre o tamanho dos PRs e o feedback final das revisões?
- **RQ02:** Qual a relação entre o tempo de análise dos PRs e o feedback final das revisões?
- **RQ03:** Qual a relação entre a descrição dos PRs e o feedback final das revisões?
- **RQ04:** Qual a relação entre as interações nos PRs e o feedback final das revisões?
- **RQ05:** Qual a relação entre o tamanho dos PRs e o número de revisões realizadas?
- **RQ06:** Qual a relação entre o tempo de análise dos PRs e o número de revisões realizadas?
- **RQ07:** Qual a relação entre a descrição dos PRs e o número de revisões realizadas?
- **RQ08:** Qual a relação entre as interações nos PRs e o número de revisões realizadas?

## Hipóteses iniciais

Antes da análise estatística, foram formuladas hipóteses para cada questão de pesquisa:

- **RQ01:** PRs maiores (mais arquivos, mais linhas) tenderiam a ser CLOSED, por maior complexidade.
- **RQ02:** PRs que ficam abertos por mais tempo tenderiam a ser CLOSED, refletindo dificuldade de aprovação.
- **RQ03:** PRs com descrição mais longa tenderiam a ser MERGED, por comunicar melhor a intenção da mudança.
- **RQ04:** PRs com mais comentários e participantes tenderiam a ser CLOSED, indicando mais controvérsia.
- **RQ05:** PRs maiores receberiam mais revisões, pois há mais código a inspecionar.
- **RQ06:** PRs com mais revisões levariam mais tempo para serem fechados.
- **RQ07:** PRs com descrição mais detalhada receberiam menos revisões, por serem mais fáceis de avaliar.
- **RQ08:** PRs com mais participantes e comentários acumulam mais revisões.

## **Objetivo**

Analisar quantitativamente a atividade de code review em repositórios populares do GitHub, identificando associações estatísticas entre métricas de PR e (i) o status final (MERGED/CLOSED) e (ii) o número de revisões, por meio de correlação de Spearman e sumarização por medianas.

## **2. Metodologia**

### **Passo a passo do experimento**

1. Seleção de 200 repositórios populares do GitHub (por número de estrelas), com pelo menos 100 PRs (MERGED + CLOSED).
2. Coleta de PRs via GitHub GraphQL para cada repositório selecionado.
3. Aplicação dos filtros: apenas PRs MERGED/CLOSED, com pelo menos 1 revisão e tempo de análise superior a 1 hora.
4. Consolidação do dataset e cálculo de estatísticas descritivas, correlações de Spearman e geração de gráficos.




Figura 1: Fluxograma do experimento

## Critérios de seleção

**Repositórios:** os 200 mais populares do GitHub por número de estrelas, cada um com ao menos 100 PRs (MERGED + CLOSED).

### Pull Requests:

- Status MERGED ou CLOSED (excluindo PRs ainda abertos).
- Pelo menos 1 revisão (reviews.totalCount  $\geq$  1), para excluir PRs não revisados.
- Tempo de análise superior a 1 hora, para excluir revisões automáticas por bots e pipelines de CI.

## Decisões metodológicas

- **Mediana como resumo:** as distribuições são fortemente assimétricas (cauda longa), e a mediana é mais robusta a outliers do que a média.
- **Spearman em vez de Pearson:** as métricas não seguem distribuição normal e a relação pode ser monotônica mas não linear.
- **Status binário:** para RQ01–RQ04, codificamos MERGED = 1 e CLOSED = 0, tratando o status como variável ordinal.
- **Correlação não é causalidade:** os resultados indicam associação estatística, não relação de causa e efeito.

## Métricas analisadas

| Dimensão         | Métrica                                | Coluna              |
|------------------|----------------------------------------|---------------------|
| Tamanho          | Arquivos alterados                     | files_changed       |
| Tamanho          | Linhas adicionadas                     | lines_added         |
| Tamanho          | Linhas removidas                       | lines_removed       |
| Tempo de análise | Horas entre criação e fechamento/merge | analysis_time_hours |
| Descrição        | Caracteres no corpo do PR (markdown)   | body_length         |
| Interações       | Número de participantes                | participants_count  |
| Interações       | Número de comentários                  | comments_count      |
| Dependente A     | Status final (MERGED/CLOSED)           | status              |
| Dependente B     | Número de revisões                     | reviews_count       |

### 3. Resultados

#### 3.1 Composição do dataset

O dataset final contém **6.721 PRs** coletados de 200 repositórios populares do GitHub, após aplicação dos filtros de elegibilidade.

| Status | Contagem | Percentual |
|--------|----------|------------|
| MERGED | 5.163    | 76,82%     |
| CLOSED | 1.558    | 23,18%     |

Tabela 1: Distribuição dos PRs por status

#### 3.2 Estatísticas descritivas

| Métrica             | Mediana | Média | P25 | P75   |
|---------------------|---------|-------|-----|-------|
| files_changed       | 3       | 9,8   | 1   | 8     |
| lines_added         | 47      | 423,1 | 8   | 207   |
| lines_removed       | 12      | 177,4 | 2   | 71    |
| analysis_time_hours | 37,2    | 312,6 | 5,9 | 188,4 |
| body_length         | 312     | 718,3 | 68  | 843   |
| participants_count  | 3       | 3,9   | 2   | 5     |
| comments_count      | 2       | 5,1   | 0   | 7     |
| reviews_count       | 2       | 2,8   | 1   | 3     |

Tabela 2: Estatísticas descritivas das métricas principais




Figura 2: Medianas por métrica: MERGED vs CLOSED (escala log1p)

#### 3.3 Panorama das correlações de Spearman

A Figura 3 apresenta o panorama visual de todas as correlações de Spearman calculadas para as duas dimensões dependentes (status do PR e número de revisões).




Figura 3: Correlações de Spearman: métricas  $\times$  status (Dim. A) e métricas  $\times$  revisões (Dim. B)

### 3.4 Correlações de Spearman - Status do PR (RQ01–RQ04)

| Métrica             | n     | $\rho$ de Spearman | p-valor |
|---------------------|-------|--------------------|---------|
| lines_removed       | 6.721 | +0,149             | < 0,001 |
| files_changed       | 6.721 | +0,128             | < 0,001 |
| lines_added         | 6.721 | +0,033             | 0,006   |
| body_length         | 6.721 | +0,024             | 0,046   |
| participants_count  | 6.721 | -0,015             | 0,204   |
| comments_count      | 6.721 | -0,093             | < 0,001 |
| analysis_time_hours | 6.721 | -0,228             | < 0,001 |

Tabela 3: Correlação de Spearman: métricas  $\times$  status\_bin

O fator com maior associação negativa ao merge é o tempo de análise ( $p = -0,228$ ): quanto mais tempo o PR permanece aberto, menor a probabilidade de ser MERGED. O número de comentários também se associa negativamente ( $p = -0,093$ ). Em sentido contrário, métricas de tamanho apresentam correlação positiva fraca, mas estatisticamente significativa.



## RQ01 - Tamanho × Status




Figura 4: Arquivos alterados por status. PRs MERGED têm mediana ligeiramente superior. Boxen plot; clipping p99.

## RQ02 - Tempo de análise × Status




Figura 5 :Tempo de análise por status. PRs CLOSED têm mediana ~4× maior. Boxen plot; valores acima do p99 removidos.

### RQ03 - Descrição × Status




Figura 6: Tamanho da descrição por status. Distribuições muito semelhantes ( $p = +0,024$ ). Boxen plot; clipping p99.

### RQ04 - Interações × Status




Figura 7: Comentários por status. PRs CLOSED têm mediana maior (2 vs 1). Boxen plot; clipping p99.

### 3.5 Correlações de Spearman - Número de revisões (RQ05–RQ08)

| Métrica             | n     | $\rho$ de Spearman | p-valor |
|---------------------|-------|--------------------|---------|
| participants_count  | 6.721 | +0,349             | < 0,001 |
| lines_added         | 6.721 | +0,296             | < 0,001 |
| comments_count      | 6.721 | +0,276             | < 0,001 |
| files_changed       | 6.721 | +0,256             | < 0,001 |
| lines_removed       | 6.721 | +0,166             | < 0,001 |
| body_length         | 6.721 | +0,152             | < 0,001 |
| analysis_time_hours | 6.721 | +0,038             | 0,002   |

Tabela 4: Correlação de Spearman: métricas  $\times$  reviews\_count

Todas as correlações com reviews\_count são positivas e, exceto analysis\_time\_hours, de magnitude moderada. O número de participantes é o preditor mais forte ( $\rho = +0,349$ ).

#### RQ05 - Tamanho $\times$ Número de revisões




Figura 8: Densidade revisões  $\times$  linhas adicionadas ( $\rho = +0,296$ ). PRs maiores têm distribuição mais dispersa. Hist2d; clipping p99.

### RQ06 - Número de revisões × Tempo de análise




Figura 9: Densidade revisões × tempo de análise ( $p = +0,038$ ). Hexbin em escala log1p; clipping p99.

### RQ07 - Tamanho da descrição × Número de revisões




Figura 10: Densidade revisões × tamanho da descrição ( $p = +0,152$ ). Hexbin em escala  $\log_{10}p$ ; clipping p99.

#### RQ08 - Interações × Número de revisões




Figura 11: Densidade revisões × participantes. Tendência positiva clara ( $p = +0,349$ ). Hist2d em escala  $\log_{10}p$ ; clipping p99.

## 4. Discussão dos resultados

### RQ01 - Tamanho × Status

**Hipótese inicial: PRs maiores tenderiam a ser CLOSED.**

A hipótese não foi confirmada. As correlações entre tamanho e status são positivas: `lines_removed` ( $p = +0,149$ ), `files_changed` ( $p = +0,128$ ) e `lines_added` ( $p = +0,033$ ). PRs com 0–1 arquivo (Q1) têm taxa de MERGE de apenas 69%, enquanto PRs com 2–5 arquivos (Q2 e Q3) superam 83%. Uma interpretação plausível é que PRs muito pequenos correspondem a contribuições incompletas ou tentativas prematuras, enquanto PRs de tamanho moderado representam mudanças mais bem delimitadas.

### RQ02 - Tempo de análise × Status

**Hipótese inicial: PRs com mais tempo tenderiam a ser CLOSED.**

Hipótese confirmada com a correlação mais forte para status:  $p = -0,228$ . A Figura 4 evidencia a separação visual: PRs CLOSED têm mediana de tempo quase 4× maior (89h vs. 23h). PRs que levantam controvérsias, requerem muitas iterações ou não se alinham com a visão dos mantenedores ficam pendentes por mais tempo e acabam sendo fechados. Vale notar que o abandono também contribui: PRs ignorados ficam abertos por muito tempo e são eventualmente fechados sem merge.

### RQ03 - Descrição × Status

**Hipótese inicial:** *Descrições mais longas associadas a MERGED.*

Hipótese parcialmente confirmada, mas com efeito mínimo:  $p = +0,024$  ( $p = 0,046$ ). A variação na taxa de MERGE entre quartis de body\_length é de apenas ~3 pontos percentuais. A extensão da descrição, por si só, tem pouco poder preditivo sobre o desfecho, a qualidade e o alinhamento com o projeto importam mais do que o comprimento.

### RQ04 - Interações × Status

**Hipótese inicial:** *Mais interações associadas a CLOSED.*

Resultado misto:

- **comments\_count** confirma a hipótese ( $p = -0,093$ , Figura 7): PRs CLOSED têm mediana maior de comentários (2 vs. 1), indicando que mais discussão está associada a mais dificuldade de aprovação.
- **participants\_count** não confirmou ( $p = -0,015$ ,  $p = 0,204$ , não significativo): o número de participantes, sem considerar o papel de cada um, não discrimina o desfecho.

### RQ05 - Tamanho × Número de revisões

**Hipótese inicial:** *PRs maiores receberiam mais revisões.*

Confirmada: lines\_added ( $p = +0,296$ , Figura 9), files\_changed ( $p = +0,256$ ) e lines\_removed ( $p = +0,166$ ). O resultado é esperado: mais código modificado exige mais iterações de inspeção.

### RQ06 - Tempo de análise × Número de revisões

**Hipótese inicial:** *PRs com mais revisões levariam mais tempo.*

Confirmada com efeito fraco:  $p = +0,038$  ( $p = 0,002$ ). A associação existe, mas é pequena. O tempo alto de PRs CLOSED, que frequentemente têm poucas revisões, dilui a correlação no conjunto total.

### RQ07 - Descrição × Número de revisões

**Hipótese inicial:** *Descrições mais detalhadas levariam a menos revisões.*

Não confirmada: a correlação é positiva ( $p = +0,152$ ). PRs com descrições mais longas tendem a receber mais revisões. A interpretação mais provável é que PRs mais complexos, que naturalmente acumulam mais revisões, também têm descrições mais elaboradas, a descrição reflete a complexidade, não a reduz.

### RQ08 - Interações × Número de revisões

**Hipótese inicial:** *Mais participantes e comentários levam a mais revisões.*

Confirmada com as maiores correlações do grupo: participants\_count ( $p = +0,349$ , Figura 8) e comments\_count ( $p = +0,276$ ). PRs que atraem mais colaboradores também recebem mais ciclos de revisão, indicativo de maior engajamento da comunidade.

### Limitações

- **Viés de seleção:** a amostra representa repositórios muito populares (top-200 por estrelas), não o ecossistema GitHub como um todo.

- **Limite de PRs por repositório:** a coleta usa um teto de PRs verificados por repositório, o que pode enviesar a amostra para contribuições mais recentes.
- **Causalidade:** todas as correlações são observacionais. Não é possível afirmar que uma variável causa a outra.
- **Variáveis não controladas:** linguagem de programação, tipo de mudança, presença de bots de revisão, políticas de cada repositório e histórico do autor são fatores que podem influenciar as associações observadas.

## Síntese das hipóteses

O quadro abaixo sintetiza os resultados de cada questão de pesquisa:

| RQ                          | Hipótese confirmada? | Principal resultado                                                            |
|-----------------------------|----------------------|--------------------------------------------------------------------------------|
| RQ01: Tamanho × Status      | Não                  | Tamanho moderado → maior taxa de MERGE; PRs muito pequenos são mais rejeitados |
| RQ02: Tempo × Status        | Sim                  | PRs CLOSED têm mediana de tempo ~4× maior ( $p = -0,228$ )                     |
| RQ03: Descrição × Status    | Parcialmente         | Efeito positivo mínimo ( $p = +0,024$ , $p = 0,046$ )                          |
| RQ04: Interações × Status   | Parcialmente         | Comentários confirmam ( $p = -0,093$ ); participantes não significativo        |
| RQ05: Tamanho × Revisões    | Sim                  | Mais linhas/arquivos → mais revisões ( $p$ até $+0,296$ )                      |
| RQ06: Tempo × Revisões      | Sim (fraco)          | Correlação positiva fraca ( $p = +0,038$ )                                     |
| RQ07: Descrição × Revisões  | Não                  | Correlação positiva ( $p = +0,152$ ); descrição reflete complexidade           |
| RQ08: Interações × Revisões | Sim                  | Participantes é o maior preditor de revisões ( $p = +0,349$ )                  |

## 5. Conclusão

Este estudo analisou 6.721 Pull Requests de 200 repositórios populares do GitHub, investigando a relação entre características dos PRs e (i) o status final (MERGED/CLOSED) e (ii) o número de revisões recebidas, por meio de correlação de Spearman e análise de medianas.

Para o **status final**, o achado mais robusto é que o tempo de análise apresenta a maior associação negativa com o merge ( $p = -0,228$ ): PRs que ficam abertos por mais tempo tendem a não ser integrados. O número de comentários reforça esse padrão ( $p = -0,093$ ). Contrariando a hipótese inicial, métricas de tamanho mostraram correlação positiva com o status, PRs moderadamente grandes têm maior taxa de MERGE do que PRs muito pequenos.

Para o **número de revisões**, o engajamento coletivo é o fator dominante: o número de participantes é o maior preditor ( $p = +0,349$ ), seguido por métricas de tamanho e de comentários. PRs que atraem mais colaboradores e têm mais código modificado tendem a acumular mais ciclos de revisão.